ИНТЕЛЛЕКТУАЛЬНЫЙ АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ

Лекция · интегрированный поток (3 курс бакалавриата + 6 курс магистратуры)

Модуль 1

Методология анализа и визуализации данных

Модуль рабочей программы курса ИАиВД

Место дисциплины в цикле работы с данными: объект и предмет, проблема «последней мили», эволюция аналитики от статистики до XAI

Занятие 1.1

Место дисциплины, эволюция области и организация курса

Лекция · 90 минут · 2 академических часа

Дорожная карта и треки BI/ML · Проблема «последней мили» · От Тьюки и Тафти до Self-Service BI и XAI

Большаков Анатолий Афанасьевич
доцент, канд. техн. наук

Булдакова Мария Алексеевна
ассистент преподавателя

05.09.2026
Санкт-Петербург

Организация курса: интегрированный поток

ПОЛИТЕХ

Единый теоретический фундамент и разделение на профильные траектории для практической реализации

Теория – совместно

Лекционные занятия проходят для всего потока: формируем общий язык аналитиков и инженеров.

Содержание блока

– Когнитивная психология восприятия.

– Информационный дизайн.

– Методы оценки моделей.

Зачем это нужно

В индустрии аналитики данных и ML-инженеры работают в единых кросс-функциональных командах – курс эмулирует эту среду.

Практика – дифференцированно

Проектирование интерфейсов на базе сквозного датасета SOC; пути расходятся по профильным траекториям.

Трек «Бизнес-аналитика» (BI)

3 курс бакалавриата. Инструмент: **Qlik Sense Desktop**. Дескриптивная аналитика и EDA.

Трек «Инженерия ML» (ML)

5 курс магистратуры (бакалавры – по заявлению). Инструменты: **Python, Taipy, Plotly**. Предиктивная аналитика и XAI.

Лекции – вместе, практика – по траекториям: общий фундамент, разные инструменты

Профильный трек «BI-аналитика»

ПОЛИТЕХ

Базовый трек: фокус на дескриптивной аналитике и разведочном анализе данных (EDA)

Целевая аудитория

3 курс – базовый трек потока.

Инструмент

Qlik Sense Desktop – платформа с ассоциативной моделью данных: миллионы строк исследуются в оперативной памяти, без написания кода.

Сквозной кейс

Датасет службы информационной безопасности (SOC): поиск аномалий в сотнях тысяч алертов.

Задачи трека

– Загрузка и подготовка данных.

– Анализ множеств (**Set Analysis**).

– Разведочный анализ (EDA): выявление аномалий в исторических данных.

– Конструирование интерактивных дашбордов.

Результат

Аналитик SOC сам «крутит» данные и за пару кликов переходит от общей картины к расследованию конкретной аномалии.

Фокус трека – дескриптивная аналитика: отвечаем на вопрос «Что произошло?»

Профильный трек «ML-инженерия»

ПОЛИТЕХ

Продвинутый трек: интеграция предобученных моделей и методов объяснимого ИИ в веб-интерфейсы

Целевая аудитория

5 курс; 3 курс(бакалавры) – по заявлению и результатам входного тестирования по Python.

Инструменты

Python, фреймворк **Taipy**, библиотека **Plotly**: разработка полноценных веб-приложений (Data Apps).

Сквозной кейс

Тот же датасет SOC: интерфейс, где предсказание модели сопровождается визуальным объяснением.

Задачи трека

– Инференс предобученных ML-моделей (**.joblib**).

– Асинхронные вызовы моделей.

– Визуализация объяснимого ИИ (**XAI**): графики **SHAP** и **PDP** в пользовательском интерфейсе.

Результат

Приложение не просто выдаёт предсказание, а визуально доказывает аналитику SOC, почему модели можно доверять.

Фокус трека – предиктивная аналитика: предсказание модели + объяснение ее логики

Дорожная карта курса и аттестация

15 недель командной работы (2–3 человека), три контрольных точки, зачет с оценкой

Итоговый контроль

Классического экзамена по билетам не будет. Форма итогового контроля — **зачёт с оценкой** в формате публичной защиты группового проекта.

Как складывается оценка

Командная защита проекта по рубрикатору + индивидуальные ответы на вопросы. «Спрятаться в команде» не получится.

Раздаточный материал

«Дорожная карта курса и рубрикатор оценки группового проекта» — в СДО.

КТ 1 · Архитектурное ревью — нед. 13, после модуля 3

Перекрёстная оценка: команды рецензируют интерфейсы друг друга.

КТ 2 · Предзащита — нед. 15

Работоспособность приложений, критические ошибки, корректность формул.

КТ 3 · Итоговая защита — сессия

Аналитическая обоснованность, информационный дизайн, техническая реализация.

Рубрикатор: аналитика 30% • информационный дизайн 30% • техническая реализация 40%

Объект и предмет дисциплины

ПОЛИТЕХ

Переход от математических алгоритмов к человекоцентричным интерфейсам

Объект

Массивы данных, результаты работы ML-алгоритмов и аналитические системы.

Примеры

– Логи SIEM: миллионы событий и алертов.

– Выводы моделей: вероятности, классы, метрики.

– Аналитические отчёты и выборки.

Предмет

Методы трансформации алгоритмических вычислений в визуальные интерфейсы поддержки принятия решений.

Инструменты трансформации

– Визуальные кодировки: длина, позиция, цвет, тренд.

– Принципы информационного дизайна.

– Методы объяснимого ИИ (XAI).

Курс – о том, что происходит с результатами вычислений, когда на них смотрит живой человек

Разрыв в Data Science

ПОЛИТЕХ

Высокая точность математической модели не гарантирует её внедрение в бизнес-процессы

Язык Data Science

– ROC AUC

– F1-score

– Градиентный бустинг

– «Алгоритм сходится»

Так говорит датасаентист, отчитываясь о качестве модели

разрыв

Язык бизнеса

– Снижение рисков

– ROI

– SLA

– Стоимость ошибки

Так мыслит руководитель SOC, принимая решение

Между математикой и бизнесом – пропасть: F-score 0.9 ничего не говорит руководителю

Проблема «последней мили» (The Last Mile Problem)

ПОЛИТЕХ

Самая сложная задача – «доставить» математический вывод в мозг бизнес-заказчика

Вывод ML-модели

Массив вероятностей: [0.01; 0.89; 0.05; 0.99]

Что с этим делать дежурному инженеру?

«Последняя миля»

Перевод вычислений на язык управленческого решения

Решение бизнеса

У руководителя дежурной смены SOC – 3 минуты: изолировать сервер или проигнорировать алерт

Как в логистике самый сложный и дорогой этап – доставка посылки от распределительного центра до двери клиента, так и в Data Science самое сложное – «доставка» математического вывода в мозг заказчика.

Тысячи ML-моделей легли «в стол» именно на этапе последней мили: их авторы не смогли объяснить бизнесу, почему алгоритму можно доверять.

Аналитик данных – это переводчик с машинного языка на язык управленческих решений

Визуализация – мост через разрыв

ПОЛИТЕХ

Инструменты курса переводят математическую абстракцию в визуальные кодировки: длину, цвет, позицию, тренд

Сырые данные и вычисления: логи SIEM · SQL-запросы · model.fit() и model.predict() · метрики качества

Визуальный интерфейс поддержки решений

Дашборд Qlik Sense (трек BI) · Веб-приложение Taipy (трек ML)

Действие человека: руководитель дежурной смены SOC за 3 минуты принимает решение – изолировать сервер или проигнорировать алерт

Аналитика не имеет ценности, если она не приводит к решениям (К. Андерсон)

Роли индустрии данных и треки курса

ПОЛИТЕХ

Две роли–«строителя» соответствуют трекам курса; аналитик SOC – сквозной заказчик семестра

BI-аналитик
Исторические данные, дашборды — вопрос «что произошло?»

Data Scientist — смежная роль
Модели и метрики — «что произойдёт?»; математика — за рамками курса

ML-инженер
Промышленная эксплуатация моделей (Data Apps)

Аналитик SOC
Решения в условиях потока алертов — главный потребитель аналитики

Маппинг на курс

Трек **«BI-аналитика»** → роль BI-аналитика

Трек **«ML-инжиниринг»** → роль ML-инженера

Аналитик SOC — сквозной заказчик всех проектов семестра

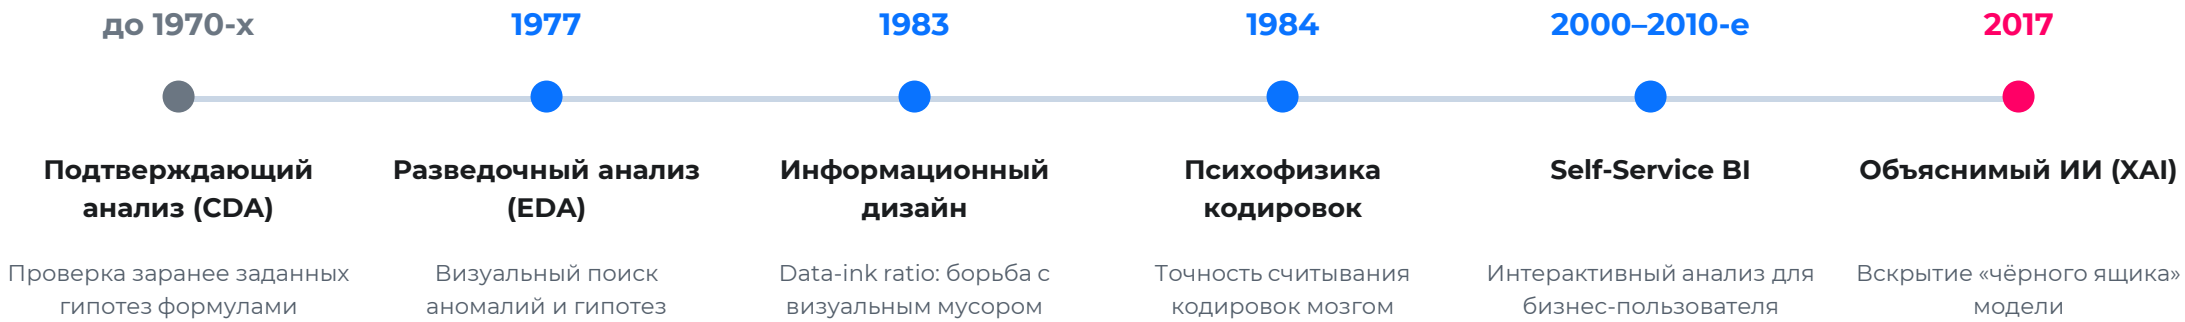
Аналитик SOC появится на следующей лекции как главный герой сквозного кейса.

Обе роли-строителя работают на одного заказчика – аналитика SOC

Эволюция области: от статистики к дизайну

ПОЛИТЕХ

Инструменты визуализации – исторический ответ на кризисы обработки информации



Современные графики и подходы появились не случайно – это эволюционный ответ науки на рост объёмов данных. Каждый следующий этап решал кризис предыдущего и формировал логику нашего курса.

Каждый этап эволюции – отдельный модуль нашего курса

До 1970-х: подтверждающий анализ (CDA)

ПОЛИТЕХ

Данные использовались исключительно для проверки заранее сформулированных гипотез

Гипотеза

Учёный заранее формулирует предположение

Математический аппарат

Данные прогоняются через формулы статистики

Подтверждение / опровержение

Бинарный ответ «да / нет»

Визуализацию считали необязательной: строгих формул статистики якобы достаточно. Данные были «немыми» – они не могли подсказать ничего сверх исходной гипотезы.

Классическая статистика отвечала только на заранее заданный вопрос – но не помогала увидеть неизвестное

1977 год: разведочный анализ данных (EDA)

ПОЛИТЕХ

Визуализация как инструмент поиска неизвестных аномалий

Джон Тьюки (John Tukey)

Книга «Exploratory Data Analysis», 1977

Революция подхода

Прежде чем проверять гипотезы, нужно позволить данным самим подсказать эти гипотезы – и лучший способ сделать это: **визуализировать данные**.

Связь с курсом

Весь Модуль 2 построен на подходе Тьюки: аномалии в датасете SOC мы ищем визуально, до написания model.fit().

Инструменты, введённые Тьюки

– Гистограммы – форма распределения.

– «Ящики с усами» (box plot) – медиана, разброс, выбросы.

– Точечные графики – связи и паттерны.

Зачем это аналитику SOC

Прежде чем блокировать IP-адрес, аналитик визуально оценивает распределение: не прячется ли за выбросом таргетированная атака. Визуализация – первый инструмент детектирования неизвестного.

«Позвольте данным самим подсказать гипотезы» – основа Модуля 2

1983 год: информационный дизайн

ПОЛИТЕХ

Превращение визуализации из «рисования» в строгую инженерную дисциплину

Эдвард Тафти (Edward Tufte)

«The Visual Display of Quantitative Information», 1983

Контекст

С появлением ПК графики стали «украшать»: тени, 3D, градиенты. Тафти остановил это, введя математическую метрику мусора.

Принцип

Каждый пиксель, не отражающий значение данных, – информационный мусор (chartjunk), и он должен быть удалён.

Концепция Data-ink ratio

$$Data - ink\ ratio = \frac{\text{«чернила» данных}}{\text{все «чернила» графика}}$$

Связь с курсом

Аналитик SOC работает в условиях стресса и лимита времени (SLA). 3D-эффекты, толстые сетки и градиенты заставляют глаз тратить миллисекунды на расшифровку мусора.

За визуальный шум в проектах – **штраф по рубрикатору**: 30%. оценки – информационный дизайн.

График не должен быть красивым – он должен быть честным и эффективным

1984 год: психофизика кодировок

ПОЛИТЕХ

Математическое обоснование точности человеческого восприятия геометрии

Уильям Кливленд и Роберт Макгилл

Эксперименты по точности считывания графиков, 1984

Что сделали

Провели тесты на людях на стыке математики, биологии и когнитивной психологии: измерили, насколько точно мозг считывает разные визуальные кодировки.

Результат

Строгая иерархия точности кодировок – от позиции на шкале до интенсивности цвета.

Логика эволюции

– Тьюки сказал, *что* делать: исследовать данные визуально.

– Тафти сказал, *как*: чисто, без мусора.

– Кливленд и Макгилл ответили, *какие формы* работают лучше всего.

Связь с курсом

Матрица выбора диаграмм (Модуль 2) опирается на эту иерархию: мы выбираем графики на длине и позиции, а не на углах и площадях.

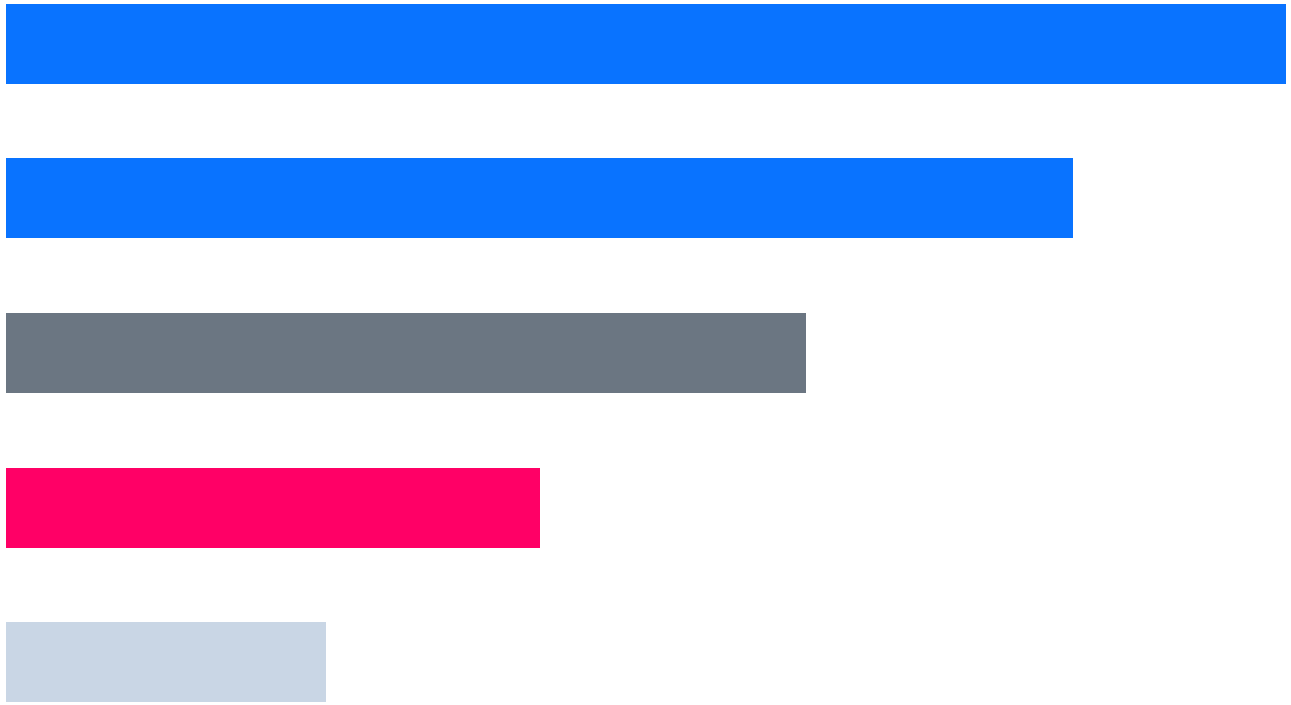
Психофизика данных: какие формы мозг считывает точнее всего

Иерархия точности визуальных кодировок

ПОЛИТЕХ

Длина оценивается мозгом точнее, чем площадь или интенсивность цвета

1. **Позиция на общей шкале**
   Точечный график
2. **Длина**
   Столбчатая диаграмма
3. **Угол и наклон**
   Круговая диаграмма – сравнение секторов
4. **Площадь**
   Пузырьковая диаграмма – сравнение кругов
5. **Интенсивность цвета**
   Тепловая карта – только «больше / меньше»



Круговая диаграмма использует угол и площадь – самые неточные каналы восприятия

2000–2010-е: аналитика самообслуживания (Self-Service BI)

ПОЛИТЕХ

Переход возможности анализа от ИТ-инженеров напрямую к бизнес-пользователям

OLAP-эпоха: ИТ-отдел как «узкое горлышко»

1. Руководитель SOC просит отчёт по инцидентам за месяц.
2. ИТ-отдел пишет SQL-запросы и собирает данные.
3. Через неделю – статичный PDF-отчёт.
4. Новый разрез данных (например, по IP-адресу) – цикл повторяется заново.

Self-Service BI: интерактивная фильтрация

– Миллионы строк загружаются в оперативную память.

– Пользователь сам фильтрует данные и меняет визуализации без кода.

– Платформы нового поколения: Qlik Sense, Tableau.

Связь с курсом

Это эпоха трека BI: ассоциативная модель Qlik Sense позволяет аналитику мгновенно переходить от сотен тысяч алертов к конкретной аномалии.

От статичных отчётов ИТ-отдела – к самостоятельному исследованию данных бизнесом

Современность: кризис «чёрного ящика»

ПОЛИТЕХ

Экстремально высокая точность ансамблевых моделей породила полное непонимание их логики

Вход

Миллионы событий SIEM: логи, алерты, телеметрия. Человек с дашбордом уже не справляется – нужна автоматизация.

«Чёрный ящик»

Ансамбль из 1000 деревьев решений. Точность 99%. Внутренняя логика непрозрачна.

Решение модели

Модель **блокирует** учётную запись генерального директора, классифицировав его активность как атаку.

Директор в ярости требует объяснений. Датасаентист отвечает: «Не знаю – модель состоит из 1000 деревьев, но историческая точность 99%».

В этот момент модель отправляется в корзину: в критических отраслях (ИБ, медицина, финансы) бизнес и регуляторы не принимают слепые алгоритмические решения.

Точность 99% не спасает модель, которой бизнес не может доверять

2017 год: объяснимый ИИ (Explainable AI / XAI)

ПОЛИТЕХ

Вскрытие «чёрного ящика» с помощью математического аппарата теории игр

Скотт Лундберг, Су-Инь Ли

2017: значения Шепли из теории коалиционных игр – метод **SHAP**

Кристоф Молнар

Монография «Interpretable Machine Learning» – систематизация методов XAI

Суть подхода

Для каждого предсказания вычисляется вклад каждого признака: какие параметры повысили вероятность атаки, а какие – снизили.

Объяснение для аналитика SOC

Модель заблокировала директора, потому что:

- ↑ Обфусцированная командная строка — **существенно повысила** вероятность вердикта «атака»
- ↑ Скрытое выполнение PowerShell — **повысило** вероятность
- ↓ Время суток — **снизило** вероятность

Модель превращается из автономного «терминатора» в прозрачного советчика – основа трека ML

Этапы эволюции и модули курса

ПОЛИТЕХ

Каждая историческая веха подробно разбирается в соответствующем модуле программы

Исторический этап / концепция	Автор / год	Где изучается в курсе
Разведочный анализ (EDA)	Дж. Тьюки, 1977	Модуль 2 · Лекция 2.4
Data-ink ratio: борьба с визуальным мусором	Э. Тафти, 1983	Модуль 2 · Лекция 2.2
Психофизика кодировок	У. Кливленд, Р. Макгилл, 1984	Модуль 2 · Лекция 2.1
Аналитика самообслуживания (Self-Service BI)	Развитие индустрии, 2010-е	Практики трека BI (Qlik Sense)
Значения Шепли в ML (SHAP)	С. Лундберг, С.-И. Ли, 2017	Модуль 3 · Лекция 3.4

Структура курса повторяет логику эволюции области: от EDA до объяснимого ИИ

Ключевая литература курса

ПОЛИТЕХ

Три книги – компас курса: сторителлинг, культура данных, объяснимый ИИ

1. К. Нассбаумер Нафлик. «Данные: визуализируй, расскажи, используй. Сторителлинг в аналитике» (2025).

Основная книга по сторителлингу и борьбе с визуальным мусором.

2. К. Андерсон. «Аналитическая культура. От сбора данных до бизнес-результатов» (2017).

Как внедрять data-driven подход: аналитика ценна, только когда приводит к решениям.

3. C. Molnar. «Interpretable Machine Learning: A Guide for Making Black Box Models Explainable» (электронный ресурс).

Базовый труд по методам XAI: SHAP, PDP и другие техники интерпретации моделей.

Где искать полный список

Полный перечень литературы — в РПД; первоисточники исторического блока — в списке источников занятия 1.1.

По РПД Молнар и Андерсон — дополнительная литература, но для нашего курса они ключевые.

Три книги – компас курса: сторителлинг, культура данных, объяснимый ИИ

Резюме: цель дисциплины

ПОЛИТЕХ

Курс не про математику алгоритма, а про интерфейс между алгоритмом и человеком

Это не курс по рисованию красивых картинок и не курс по математическому выводу алгоритмов – их вы изучаете на других дисциплинах.

Трансформация сырых вычислений в научно обоснованные визуальные интерфейсы поддержки принятия решений

Научный фундамент курса: гештальтпсихология · психофизика визуальных кодировок · методы объяснимого ИИ (XAI).

Сквозной полигон семестра – логи системы безопасности (SIEM): вы спасаете аналитиков SOC от когнитивной перегрузки.

Наша работа – закрыть «последнюю милю» между вычислением и управленческим решением

Итоги занятия и самостоятельная работа

ПОЛИТЕХ

Что освоили на лекции и что нужно сделать до установочного практикума 1.4

Что освоили сегодня

- ✓ Объект и предмет дисциплины.
- ✓ Суть проблемы «последней мили» в Data Science.
- ✓ Вехи эволюции: EDA, Data-ink ratio, психофизика, Self-Service BI, XAI.
- ✓ Дорожная карта курса: 15 недель, 3 контрольные точки.
- ✓ Профильные траектории BI и ML и их инструменты.

Самостоятельная работа к занятию 1.4

1. Изучить РПД и рубрикатор оценки проекта.
2. Сформировать команды (2–3 человека).
3. Выбрать профильную траекторию (BI или ML).
4. Установить ПО по чек-листу: Qlik Sense Desktop или Python / VS Code / Taipy.
5. Прочитать: К. Андерсон, «Аналитическая культура» (главы о data-driven подходе).

Далее – лекция 1.2: погружение в предметную область SOC

Контрольные вопросы

ПОЛИТЕХ

Самопроверка по итогам лекции: вопросы 1–4 — теория, вопросы 5–6 — организация курса

1. В чём заключается суть проблемы «последней мили» в Data Science?

2. Почему ML-модель с высокой точностью (Accuracy) может быть отклонена бизнес-заказчиком в промышленной эксплуатации?

3. Какой вклад внёс Джон Тьюки в современный анализ данных? В чём отличие EDA от подтверждающего (confirmatory) анализа?

4. Почему концепция объяснимого ИИ (XAI) стала актуальной именно в последнее десятилетие?

5. Какие роли существуют в индустрии данных и ИБ? Каким трекам курса они соответствуют?

6. Назовите три контрольные точки (КТ) при подготовке группового проекта в рамках курса.

Анонс: лекция 1.2—погружение в предметную область SOC

ПОЛИТЕХ

Открываем полигон курса — учебный датасет на основе реальных логов центра мониторинга безопасности

Что разберём на лекции 1.2

— Что такое **SIEM** и **SOC**: как устроен центр мониторинга ИБ.

— Архитектура сквозного датасета алертов.

— Анатомия карточки инцидента: из каких полей состоит кибералерт.

— Почему человек — обязательное звено системы (**Human-in-the-loop**).

Откроем полигон курса — учебный датасет на основе реальных логов SOC (**~274 000 строк**).

Важно про данные

Датасет синтетический: построен на основе реальных паттернов логов — вопросы персональных данных не возникают.

Поймём, с чем именно будем работать весь семестр.

Аналитик SOC – главный герой сквозного кейса семестра

Вопросы?